在线机器人从原始感知中形成空间智能

Related Research 中文综述

研究焦点：无预训练、原始视觉与单个 IMU、未知动作后果、真实时间在线学习、追踪行为与 metric representation 的自主涌现。

文献范围

重点覆盖 2019-2026 年的主动高效编码、Dreamer/RSSM、内在探索、端到端 JEPA、具身自监督学习及真实机器人在线 world model。

版本：2026 年 8 月 27 日

用途：研究定位、baseline 选择、实验设计与论文 related-work 草稿基础

01 结论摘要

现有研究已经分别实现了：真实机器人从零在线学习、基于世界模型的主动探索、双目追踪与自校准、从 raw pixels 学习物理 latent，以及通过视觉-运动一致性产生表征。但是，本综述未发现一项工作同时满足你的全部条件。

你的目标条件可以写成以下交集：

随机初始化 + raw vision/IMU + 真实连续交互 + 动作后果自校准 + intrinsic curiosity + tracking emergence + metric latent emergence + 长期持续记忆

最接近的四条研究路线分别是：

Active Efficient Coding（AEC）：最接近“追踪与视觉控制自主涌现”，但主要在仿真中。

DayDreamer 与 MPAIL2：最接近“真实机器人、从零、在线 world-model learning”。

LeWorldModel：最接近“raw pixels 中物理 latent structure 的形成与 probing”。

E-SSL：最接近“视觉与 IMU/运动信号通过 sensorimotor contingency 共同塑造表征”。

因此，你的潜在贡献并不是重新发明 world model，而是把这些此前分开的方向统一到一个受限的机器人头部平台上，并对“空间 metric 与 tracking 是否共同涌现”进行可证伪的实验。

需要谨慎的地方

不能只凭 latent 可视化声称模型具有空间理解；需要 held-out probe、局部距离保持和跨场景泛化。

不能只凭机器人看向物体声称 tracking 涌现；必须排除固定 kernel、显式 centering reward 或人为目标标签造成的行为。

在完成系统性的数据库检索前，不宜直接声称“first”；更安全的表述是“现有文献尚未共同验证这些条件”。

02 研究问题与比较标准

这里的“空间智能”不是普通目标检测，也不是把 SLAM 输出作为网络输入。它至少包含三个层次：

Sensorimotor calibration：模型通过交互发现动作向量如何改变图像和 IMU。

Spatial representation：latent 中保留相对方向、位移、深度或运动结构。

Spatial behavior：模型利用该结构形成 fixation、pursuit、reacquisition 或主动视角选择。

比较轴	严格含义	与你的实验关系
From scratch	encoder、dynamics 和 policy 均不使用外部预训练权重	排除互联网语义先验
Online	数据产生、更新与行为执行在同一个持续交互过程中发生	检验真正的 developmental learning
Raw sensory	图像和 IMU 进入模型；不输入 pose、depth、segmentation 或目标坐标	保证 metric 不是直接提供的
Intrinsic objective	行为由预测、信息增益或编码效率驱动，而不是任务完成奖励	决定 tracking 能否算作涌现
Metric evidence	冻结 representation 后，用未参与训练的 ground truth 做 probe 和几何检验	区分“能预测”与“形成空间结构”
Persistence	学习新对象后仍保留旧对象知识	对应 replay 与慢速长期记忆

03 文献地图：谁实现了哪一部分

研究	零预训练	真实在线	Intrinsic	空间表征	追踪
AEC 2019/2021	是	否：仿真	编码效率	视差/3D 运动 tuning	是
Plan2Explore 2020	是	否：控制仿真	ensemble disagreement	未作为主要指标	否
DayDreamer 2023	是	是	否：任务奖励	未专门验证	非研究目标
V-JEPA 2 2025	否	部署时规划	否：视觉目标	强物理先验	非自主涌现
MPAIL2 2026	是	是	学习自示范的 reward	task-agnostic latent dynamics	非主要指标
LeWorldModel 2026	是	否：数据集训练	否：目标图像	probe 可恢复物理量	否
E-SSL 2026	是	否：录制数据	TC + SMC 自监督	语义/几何表征	不控制机器人

如何阅读这张表

“真实在线”不等于“自主发现任务”。DayDreamer 在线学习，但奖励告诉它要走路或到达目标；MPAIL2 不使用手写 reward，但示范视频定义了任务；V-JEPA 2 在部署时进行在线规划，但 representation 来自大规模预训练。

同样，“latent 能预测未来”不自动等于“latent 具有 metric”。metric 需要额外的冻结表示评估，并且标签只能用于评估，不能反向训练 world model。

04 Active Efficient Coding：最接近自主追踪涌现

代表论文

Lelais et al., 2019, Autonomous Development of Active Binocular and Motion Vision Through Active Efficient Coding。Wilmot et al., 2021 将 sparse coding 扩展为 deep autoencoder。

核心闭环

双目图像 → 学习视觉编码 → 编码效率/重建误差 → reinforcement learner → vergence 与 pursuit 动作 → 新图像

它的重要性不在于网络结构先进，而在于证明了一个发展性命题：系统并没有直接获得目标角度，却能够因为改善感知编码而自校准 fixation 和 smooth pursuit。2019 工作还报告了 disparity、motion 与 motion-in-depth tuning 的形成。

与你的直接对应

AEC 的 coding-efficiency reward 对应你的 prediction correctness 与 information preference。

AEC 的摄像头运动控制对应你的 Ex、Ey → 固定 PID。

AEC 的视觉 tuning emergence 对应你的 latent metric 与运动表征探测。

关键差距

主要在 iCub 仿真中验证，而不是持续的真实机器人在线学习。

没有 RSSM 的 stochastic belief state，也没有 vision-IMU cross-prediction。

直接使用 reconstruction/coding error 容易被噪声吸引；你的 ensemble uncertainty 与时间衰减可作为改进。

对你的意义

AEC 应当成为行为涌现 baseline。若你的系统不能超过 AEC 风格的编码效率控制，就很难证明复杂 RSSM、PDE 与长期记忆的必要性。

05 Dreamer 系列：真实在线学习与主动探索

DayDreamer（Wu et al., 2023）

DayDreamer 将 Dreamer 用到四种真实机器人上，不依赖模拟器。论文展示了四足机器人从零学习翻身、站立和行走，机械臂从相机图像和稀疏奖励学习抓放，以及轮式机器人从图像学习目标导航。

其关键工程贡献是证明 RSSM + replay + imagined actor-critic 可以在真实机器人交互预算下工作。它非常适合做你的主要代码和训练稳定性 baseline。

> 但 DayDreamer 回答的是“给定 reward 后能否学会任务”，而不是“没有 tracking reward 时 tracking 是否会因为信息规律自行出现”。

Plan2Explore（Sekar et al., 2020）

Plan2Explore 在 Dreamer world model 上加入多个 one-step latent predictors。模型在熟悉区域趋于一致，在数据不足区域产生 disagreement：

$$r_{int}(s,a) = \mathrm{Var}_k [\, f_k(s,a) \,]$$

探索 actor 在 world model 中想象未来，并最大化累计 disagreement，而不只是选择当前最不可预测的动作。这解决了“必须先经过熟悉区域才能到达未知区域”的问题。

与你的差别

- Plan2Explore 的 curiosity 是 scalar；你的 PDE 将其扩展为空间信息场 c(x,t)。
- Plan2Explore 没有 innate edge/color/motion kernels，也没有 Day-0 gaze behavior。
- Plan2Explore 不检验 metric representation、IMU consistency 或长期记忆。

06 MPAIL2：2026 年最接近的真实机器人在线工作

Han et al. 的 MPAIL2 研究 real-world inverse reinforcement learning from observation。其 encoder、latent dynamics、reward、value 与 policy 全部在线更新，并明确报告不使用预训练、仿真和在线人工 reward。

基本 world model

$$z_t = e(o_t),\ z_hat_(t+1) = f(z_t,\ a_t)$$

真实交互 (o_t, a_t, o_(t+1)) 进入 replay buffer，latent dynamics 使用多步预测损失训练。规划器在 latent 中采样动作序列，并用学习得到的 reward 与 value 评价。

论文在真实 Franka 与 Kinova 平台上使用 64×64 RGB、外部/腕部相机和 proprioception；报告了从零学习 push、pick-and-place 等任务，并展示 positive online transfer。

为什么仍不等于你的目标

- MPAIL2 仍然接收 observation-only expert demonstrations；示范序列告诉系统什么结果是好的。
- 它研究的是任务模仿和操作成功率，而不是空间 metric、追踪或自主 curiosity。
- 它的动作接口是机械臂 action space；没有专门研究一个模型如何从 vision-IMU effects 中发现 pan/tilt 轴的意义。

最值得借鉴的部分

> MPAIL2 是证明“随机初始化的小型 latent model 可以在真实机器人上边行动边学习”的强证据。它也提供 replay、off-policy 更新和 online planning 的近期工程参考。

07 LeWorldModel 与 E-SSL：物理 latent 如何形成

LeWorldModel（Maes et al., 2026）

LeWorldModel 是一个约 15M 参数的端到端 JEPA world model。它直接从 pixels 学习 encoder 与 action-conditioned predictor，不依赖 pretrained features，并通过 SIGReg 约束 latent distribution 以避免 collapse。

$$L = L_{prediction} + \lambda \cdot SIGReg(Z)$$

论文最重要的相关性来自评估：作者冻结 latent，并训练小型 supervised probes，检测 agent location、block location 和 block angle 是否可以恢复。t-SNE 也显示了一定空间邻域结构。

不过，它使用已有 action-video 数据训练，测试时由目标图像指定任务并通过 CEM 规划。它并不研究持续在线探索或追踪行为。

Embodied Self-Supervised Learning（Aubret, 2026 preprint）

E-SSL 使用 temporal consistency（相邻观察保持表征一致）和 sensorimotor contingency（运动信号与视觉变化相匹配）进行表征学习：

$$L_{E\text{-}SSL} = L_{temporal\ consistency} + \alpha \cdot L_{sensorimotor\ contingency}$$

该工作使用约 300 小时人类第一人称视频，以及 eye tracking、头部轨迹和 IMU-derived movement。结果支持这样一个观点：运动与视觉后果的对齐能够改善语义和几何视觉表示。

但数据来自预先录制的人类经验；模型不在线控制身体，也不能证明它会自主选择动作来改善表征。

对你的组合启示

> 可以在 RSSM world-model loss 之外增加一个明确的 vision-IMU/action contingency objective，要求 latent visual transition 能预测 IMU 变化，同时 IMU 与 action 能预测 latent visual transition。

08 V-JEPA 2：强对照，但不是相同科学问题

V-JEPA 2 是 1.2B 参数的 video world model。它先在超过一百万小时视频和一百万张图像上进行 actionless pretraining，再使用约 62 小时机器人数据进行 action-conditioned training，之后可通过视觉目标和 MPC 完成 robot planning。

> 它证明了大规模视频预训练可以产生强物理先验，但不能回答你的问题：一个没有互联网经验、仅依靠自身摄像头、IMU 和动作后果的机器人是否能在几小时或几天内形成稳定空间结构。

建议的实验角色

不要把 V-JEPA 2 权重放进主要实验，否则会破坏“from scratch emergence”的因果解释。

可以把冻结 V-JEPA 2 encoder 作为上限对照：比较大规模先验与本体在线经验的样本效率。

如果资源有限，不必实际运行 1.2B 模型；文献结果可作为 qualitative reference。

SLAM、NeRF 与 3D Gaussian Splatting 为什么不属于同一问题

这些系统确实构建空间 representation，但通常显式使用相机几何、pose optimization、depth、multi-view projection 或已知坐标系。它们适合作为 evaluation oracle，而不适合作为你的学习输入，否则 metric 不再是 emergent。

09 你的研究应如何定位

推荐的一句话研究命题

研究一个随机初始化的具身 world model，是否能够仅通过原始视觉、单个偏心 IMU 和自身二维控制后果，在持续在线学习中共同形成可测量的空间 metric 与预测性追踪行为。

研究路线之间的桥接

AEC active vision + Dreamer/RSSM online world model + Plan2Explore epistemic exploration + E-SSL sensorimotor contingency + LeWorldModel latent probing + slow episodic consolidation

可能的独立贡献

从 dimensionless Ex、Ey 到视觉-IMU 后果的自主 sensorimotor calibration。

没有 pose/depth/segmentation 训练标签时，局部 metric structure 的形成。

tracking 不是显式任务奖励，而是信息获取、预测正确性和运动成本共同产生的稳定行为。

将 scalar curiosity 扩展为具有 transport、diffusion、decay 与 consumption 的 spatial information PDE。

通过 slow memory/replay consolidation 检验长期稳定性与 catastrophic forgetting。

不能过早声称的内容

latent 中单个维度必须直接等于物理角度；无监督 latent 通常只在未知可逆变换下可辨识。

在固定房间训练成功就等于一般空间智能；至少需要换物体、光照、背景和房间后的迁移实验。

预测误差下降就等于理解；模型也可能只记住纹理或时间捷径。

10 建议的最小实验与 baseline

第一阶段装置

单目相机 + 一个与相机刚性连接、但相对云台中心偏心的 IMU。

二维 pan-tilt；模型输出 Ex、Ey，底层固定 PID 负责执行。

固定房间中的球体，先静止后运动；不向训练网络提供球的位置、角度或类别。

训练输入与主要目标

$$o_t = \text{raw frame},\ u_t = \text{IMU window},\ a_t = [Ex, Ey]$$

World-model prediction：预测下一 latent、下一 IMU window 或其统计量。

Intrinsic source：ensemble disagreement + fixed perceptual kernels。

Constraints：action magnitude、jerk、joint-limit 和 continued-motion penalty。

必要 baseline

Baseline	目的	应该回答的问题
Random action	无学习下限	行为改善是否超过随机探索？
AEC-style coding reward	经典主动视觉基线	RSSM/PDE 是否提供额外价值？
Dreamer + explicit centering reward	任务监督上限	若直接告诉目标，最快能学多好？
RSSM + Plan2Explore	现代 intrinsic baseline	PDE 是否优于 scalar disagreement？
你的完整模型	核心方法	metric、tracking 和 persistence 能否同时出现？

11 如何证明 metric 与 tracking 真正涌现

A. Sensorimotor calibration

在训练时不提供角度标签。评估时记录编码器从未见过的轨迹，并检验模型能否从 (z_t, a_t) 预测视觉 flow 和 IMU response；再交换 Ex/Ey 或反转符号，观察性能是否显著下降。

B. Frozen latent probing

冻结 encoder 与 RSSM，仅使用一个小型 linear/MLP probe 从 z_t 预测真实 pan、tilt、球体 bearing 或相对运动。ground truth 只能训练 probe，不能更新 world model。

C. Metric structure

比较 ||z_i-z_j|| 与真实局部姿态差或 relative bearing 的相关性，并检查同一物体跨不同视角是否保持邻域结构。重点报告 held-out trajectories 和 held-out objects。

D. Tracking emergence

图像中心误差随训练时间下降。

追踪延迟、平滑度、jerk 和单位时间动作能量改善。

短暂遮挡后能预测性地 reacquire，而不只是响应当前 motion kernel。

关闭 learned world model 或打乱 temporal order 后，行为明显退化。

E. Continual memory

依次训练 sphere → cube → textured object，再重新测试 sphere。比较 uniform replay、recent-only replay、slow episodic memory 与 parameter consolidation，报告旧任务保持率和新任务学习速度。

最强的证据链

训练 loss 下降 → 视觉/IMU action prediction 提升 → latent metric probe 提升 → 无显式 tracking reward 的追踪行为提升 → 换物体和背景后仍保持

12 推荐阅读顺序

1. AEC 2019

先理解为什么编码效率可以同时驱动视觉表征和眼动自校准。这是与你科学问题最接近的概念祖先。

2. DayDreamer 2023

学习真实机器人 online RSSM、replay 与 actor-critic 的工程组织方式。

3. MPAIL2 2026

理解近期从零真实在线 latent modeling、off-policy training 和 planning 如何实现。

4. Plan2Explore 2020

理解 ensemble disagreement 为什么比 raw prediction error 更接近 epistemic uncertainty。

5. LeWorldModel 2026

重点阅读 collapse prevention、raw-pixel latent prediction 和 physical probing。

6. E-SSL 2026

重点阅读 temporal consistency 与 sensorimotor contingency 的分工，以及 IMU/head motion 如何参与 representation learning。

7. V-JEPA 2 2025

作为大规模预训练路线的对照，理解其强项为何不能直接回答你的 developmental learning 问题。

13 参考文献与链接

[1] Lelais et al. (2019). Autonomous Development of Active Binocular and Motion Vision Through Active Efficient Coding.
https://www.frontiersin.org/journals/neurorobotics/articles/10.3389/fnbot.2019.00049/full

[2] Wilmot, Shi & Triesch (2021). Self-Calibrating Active Binocular Vision via Active Efficient Coding with Deep Autoencoders.
https://arxiv.org/abs/2101.11391

[3] Sekar et al. (2020). Planning to Explore via Self-Supervised World Models.
https://proceedings.mlr.press/v119/sekar20a.html

[4] Wu et al. (2023). DayDreamer: World Models for Physical Robot Learning.
https://proceedings.mlr.press/v205/wu23c.html

[5] Meta AI (2025). V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning.
https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks/

[6] Han et al. (2026). Online World Modeling Enables Real-World Inverse Reinforcement Learning from Observation.
https://arxiv.org/html/2602.24121v2

[7] Maes et al. (2026). LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels.
https://le-wm.github.io/

[8] Aubret (2026). Semantic Visual Representations Emerge from Embodied Self-Supervised Learning. Preprint.
https://www.researchsquare.com/article/rs-10140180/latest

综述结论

已有工作分别证明了你的系统所需的若干组成部分，但尚未共同验证：一个仅拥有原始视觉、单个 IMU 和未知二维控制后果的真实机器人，是否可以从随机权重出发，在 intrinsic information dynamics 下形成可测量的空间 metric、追踪行为与长期稳定记忆。